刘智健 Lewis Liu

AI 应用工程师 · LLM Agent / 私有化部署 / 全栈开发

186 8052 0801 · lewis.o.liu@gmail.com · lewisliu.space · github.com/lewismessthecode · English

求职方向：AI 应用 / Agent 工程师、AI 自动化与内部工具、全栈开发 · 城市不限，可接受海外远程

简介

- 4 年软件工程经验，覆盖 LLM Agent 应用、私有化模型部署和生产级基因组数据流程。
- 发布开源项目 BioinfoFlow、Trove、Loadout、Folio。
- 分子生物学硕士，具备基因组与临床数据背景。

开源项目

BioinfoFlow　2025.12 – 至今

Agent 驱动的生信工作流平台 · 开源（MIT）· 业余项目 · bioinfoflow.com · GitHub · Python、TypeScript、FastAPI、Next.js、Docker

- 交付自然语言驱动的生信分析平台：Agent 读取项目、准备输入和参数，经用户审批后提交 Nextflow / WDL 任务，跟踪日志并解释结果。
- 实现本地优先部署，数据和算力留在用户自有机器或服务器上。
- 设计 Agent 运行时，以持久化会话、只追加历史和 `read`、`bash`、`edit`、`write`、`ask_user` 等少量通用工具支持长任务断点恢复，Agent 经 CLI 调用平台能力。
- 实现高风险操作审批，提供改动需确认、危险操作需确认、完全访问三级权限模式。
- 实现上下文压缩、重试和取消，保证长会话稳定运行。
- 搭建统一执行后端（FastAPI、Typer CLI），以一套接口驱动 Nextflow 与 MiniWDL 两种引擎。
- 实现常驻调度器，统一处理排队、资源检查、重试、超时和清理；运行状态经 SSE / WebSocket 实时推送。
- 交付 Next.js 工作台，覆盖工作区、仪表盘、Agent、工作流、运行记录（日志、DAG、产物）、镜像、调度器和设置。
- 实现 SSH 远程主机管理，支持连接测试、浏览器内终端和向 Agent 授权指定主机；远程命令运行于 Bubblewrap 沙盒。
- 以 Docker Compose 打包发布 v0.1.0、v0.2.0（2026.07），支持一行命令安装。
- 提供 nf-core/rnaseq、WDL 和 NVIDIA Parabricks WGS 示例，GPU 流程可在单张消费级 GPU（如 RTX 4080 SUPER）上运行。

Trove　2026.11

GitHub Star 仓库工作台 · 开源（MIT）· GitHub · TypeScript、Next.js、React、SQLite

- 集中管理 GitHub Star 仓库，支持标签、收藏夹和 AI 自动分类；数据存于本地 SQLite。
- 提供仓库关系图，按共享标签、收藏夹或 topic 关联仓库，采用力导向布局。
- 提供 Radar 新仓库推荐，来源包括 GitHub 搜索和 Hacker News。
- 提供 Releases 收件箱，汇总在用仓库的新版本并标出可能的破坏性更新。
- 生成 AI 仓库健康报告。
- 内置 MCP 服务，供编程助手凭 token 调用；token 由 CLI 签发和吊销。
- 支持 OpenRouter、OpenAI、Anthropic、DeepSeek、本地 Ollama 和 OpenAI 兼容服务；Ollama 仅接受本机回环地址。
- 提供中英文界面，支持 Docker Compose 部署。

Loadout　2026.10

macOS AI Agent 技能管理工具 · 开源（MIT）· GitHub · Rust、Tauri 2、React、SQLite

- 发布 v0.2.1 Universal 版本，原生支持 Apple Silicon 和 Intel Mac。
- 将 `~/.agents` 及 Claude Code、Codex、Cursor、Gemini、OpenCode 的技能合并为一份去重清单；软链接技能只显示一次，并列出全部安装位置。
- 实现应用内安装、更新和删除，更新前自动备份旧目录，删除文件移入废纸篓。
- 通过 Rust 目录扫描、防抖文件监听、日志解析和 SQLite 增量索引，从会话日志生成技能使用热力图，仅存技能名、Agent 和日期，不复制提示词和回复。
- 交付中英文界面和浅色、深色、跟随系统三种外观。
- 限定读取范围为用户主目录，不申请完全磁盘访问、自动化、辅助功能或录屏权限。

Folio　2026.11

X 长文本地阅读库 · 开源（Apache-2.0）· macOS Apple Silicon 预览版 · GitHub · TypeScript、Electron、React

- 开发 Chrome 扩展，在后台从 X 收藏导入长文，不打开或刷新 X 标签页。
- 将文章和图片存为本地 Markdown，同一文件夹可直接用 Obsidian 或 Cursor 打开。
- 实现按主题和阅读状态浏览、打分和批注。
- 接入用户自有模型 API，将选中文章整理为主题笔记和卡片，保存前由用户审核；API key 经系统安全存储加密。
- 交付中英文界面和浅色、深色、跟随系统三种外观。

工作经历

深圳华大基因 · 软件开发工程师　2022.07 – 2026.10

私有化大模型服务　2026.06 – 2026.08

- 设计并上线部门私有化大模型服务，在 8×H20 上以 vLLM 部署 DeepSeek-V4-Flash（张量并行 + 专家并行 + FP8 KV cache），通过 OpenAI 兼容 API 支撑 OpenWebUI 知识库、BioinfoFlow 及多个内部项目。
- 锁定 vLLM 镜像 digest，杜绝重新拉取导致的版本漂移。
- 搭建多租户 LiteLLM 网关，按同事、项目、服务分发 virtual key，原始模型 key 不外发。
- 实现按 key 限流，覆盖每分钟请求数、token 数、预算和并行数。
- 交付 key 管理脚本，覆盖创建、查看、禁用、恢复和轮换。
- 基于 Prometheus、DCGM exporter 和 Grafana 搭建 GPU 与推理可观测性。
- 设计容量面板，实时显示健康状态、剩余容量估算、运行与排队请求、KV cache 使用率、TTFT P95 和 TPOT P95。
- 设计用量面板，按 key 统计请求数和 token 数。
- 修复监控时间错位：定位服务器时钟快约 8 小时，在面板查询中加入补偿，并记录 NTP 修复后的回滚步骤。
- 部署 BioinfoFlow v0.2.0 至同一服务器，与 OpenWebUI 共用 LiteLLM 网关。
- 交付测序流程、WGS 和平台运维方向的可复用 Agent 技能。
- 编写运维手册，覆盖启停、key 管理、面板解读和排障。

OpenWebUI 部门知识库　2026.06 – 2026.08

- 上线全内网 OpenWebUI 部门知识库（v0.9.6），聊天、embedding、文件解析与向量检索均不出内网。
- 设计存储与解析链路：PostgreSQL 存用户、聊天和权限，PGVector 存向量，Redis 管理会话、token 撤销和 WebSocket，Apache Tika 解析 Word、PDF、PPT 和 Excel。
- 部署本地 BGE-M3 embedding 服务（1024 维），与 DeepSeek 共享同一服务器；将 DeepSeek 显存占比由 0.90 调至 0.85 以腾出资源。
- 启用混合检索，设定 chunk 大小、重叠和 top-k 初始值。
- 编写生产部署文档，覆盖 Docker Compose 配置、上线验证、备份恢复、升级、扩容条件和常见故障。
- 制定上线检查清单，包含真实业务问题召回测试和多用户负载稳定性检查。

医学 LLM 评测　2023.12 – 2024.02

- 搭建 LLM 流水线，从变异数据中提取 ACMG 证据项，辅助临床变异解读。
- 建立 Prompt 评测集 medprompt-eval。

领域微调

- 微调 LLaMA-7B 与 BioGPT，基于约 10,000 条 HPO 数据完成清洗、指令构造、训练与评估。

生产级 NGS 数据流程

- 开发和维护 10+ 条生产级 NGS 流程（泛癌、NIPT、WGS、遗传性耳聋），覆盖质控、比对、变异检测、注释和报告。
- 引入流程工程规范，包括 Git 版本管理、输入输出约定、容器化运行环境和单元测试。
- 在 HPC 集群上运行任务并排查故障。
- 沉淀异常样本、参数边界和常见失败模式文档，提升生产运行的稳定性和可复现性。

专业技能

方向	内容
AI / LLM	Agent 运行时与工具调用、Prompt Engineering、LLM 评测与 Benchmark 设计、领域微调、训练数据构建、RAG；Claude Code、Codex、Cursor
LLM 部署与运维	vLLM、LiteLLM、OpenWebUI、PGVector、BGE-M3、Apache Tika、Prometheus、Grafana、DCGM
编程语言	Python、TypeScript、Rust、Bash
后端与数据	FastAPI、Typer、SSE / WebSocket、PostgreSQL、SQLite、Redis
前端与桌面	Next.js、React、Tailwind CSS、Tauri 2、Electron
基础设施	Docker / Compose、Linux、Git、SSH、HPC、NVIDIA GPU
工作流与领域	Nextflow、nf-core、WDL、Snakemake、GATK4、Parabricks；基因组与临床变异数据
英语	CET-6

荣誉

- 阿里云天池首届世界科学智能大赛生命科学赛道冠军、创新奖（2023）：基于 DNA 甲基化数据预测生物学年龄与疾病风险。

教育

- 华南农业大学，分子生物学，本科 / 硕士，2015.09 – 2022.06。

论文

- 合著：Fast and accurate DNASeq variant calling workflow composed of LUSH toolkit. Human Genomics, 2024.